

Uso de Técnicas de Aprendizado de Máquina para Avaliação da Qualidade de Requisitos

Carla A. M. Vieira¹

¹Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica do Minas Gerais (PUC Minas)
Caixa Postal 30.535-901 – Belo Horizonte, MG – Brazil

camvieira@sga.pucminas.br

Abstract. *This meta-paper describes the style to be used in articles and short papers for SBC conferences. For papers in English, you should add just an abstract while for the papers in Portuguese, we also ask for an abstract in Portuguese (“resumo”). In both cases, abstracts should not have more than 10 lines and must be in the first page of the paper.*

Resumo. *Este meta-artigo descreve o estilo a ser usado na confecção de artigos e resumos de artigos para publicação nos anais das conferências organizadas pela SBC. É solicitada a escrita de resumo e abstract apenas para os artigos escritos em português. Artigos em inglês deverão apresentar apenas abstract. Nos dois casos, o autor deve tomar cuidado para que o resumo (e o abstract) não ultrapassem 10 linhas cada, sendo que ambos devem estar na primeira página do artigo.*

Bacharelado em Engenharia de Software - PUC Minas
Trabalho de Conclusão de Curso (TCC)

Orientador de conteúdo (TCC I): Laerte Xavier - laertexavier@gmail.com
Orientador acadêmico (TCC I): Lesandro Ponciano - lesandrop@pucminas.br
Orientador do TCC II: (A ser definido no próximo semestre)

Belo Horizonte, DIA de MÊS de ANO.

1. Introdução

A Engenharia de Requisitos é uma importante função interdisciplinar da Engenharia de Software, responsável por identificar as necessidades das partes interessadas [Souza et al. 2020] e fazer a mediação entre os domínios do adquirente e do fornecedor para estabelecer e manter os requisitos a serem atendidos pelo sistema, software ou serviço de interesse [ISO/IEC 2018]. Assim como as demais áreas da Engenharia de Software que são submetidas à normas e critérios para garantir a implementação da área definida como Qualidade de Software [ISO/IEC 2001], a Engenharia de Requisitos também desempenha um papel fundamental nesse processo uma vez que ter requerimentos de qualidade é o ponto inicial para o desenvolvimento de um software de qualidade.

Como os requisitos são escritos em linguagem natural, sua avaliação e qualidade definidas pelas características citadas geralmente se limitam ao conhecimento e experiência dos engenheiros responsáveis, o que dificulta a padronização e análise rápida

da qualidade dos requisitos. Sendo assim, o problema que este artigo procura resolver é a **falta de análises objetivas e automatizadas da qualidade de requisitos**.

O processo de definição e validação de requisitos demanda grande consumo de tempo e esforço [Gramajo et al. 2020a], destacando a importância da evolução dessa etapa do desenvolvimento de um software. Além disso, como os requisitos são escritos em linguagem natural, a flexibilidade e as características inerentes da linguagem, como inconsistências, redundâncias e ambiguidades, podem levar a erros durante a especificação e, conseqüentemente, podem influenciar negativamente as fases posteriores do ciclo de vida do software [Gramajo et al. 2020b]. Somado a importância que a etapa de Engenharia de Requisitos tem para a garantia de qualidade do software desenvolvido, os pontos levantados garantem a necessidade do aprimoramento das práticas de avaliação da qualidade dos requisitos, de forma mais objetiva e automatizada.

O surgimento de novas estratégias de aprendizagem e o aumento do poder de processamento dos computadores posicionou a Inteligência Artificial (AI, do inglês *Artificial Intelligence*) como uma ferramenta poderosa e acessível, capaz de ser implementada como um componente-chave durante o desenvolvimento de sistemas de software [Feldt et al. 2018]. A integração de tecnologias de AI na Engenharia de Software tem como objetivo de otimizar o processo de desenvolvimento de produtos de software e automatizando tarefas intensivas de esforço, a fim de obter sistemas com alta qualidade [Gramajo et al. 2020b]. Sendo assim, a utilização da Inteligência Artificial apresenta-se como uma alternativa para a evolução da qualificação de requisitos de forma objetiva e automatizada.

Desse modo, esse trabalho tem como objetivo **analisar a viabilidade de previsão automática da qualidade dos requisitos de software expressos em linguagem natural utilizando técnicas de Inteligência Artificial**. Para isso, os três objetivos específicos deste trabalho são: 1) definir um modelo de aprendizagem supervisionada para avaliação de requisitos; 2) aplicar o modelo e alimentar os conjuntos de treino e de teste; e 3) analisar sua precisão, comparando o seu desempenho com o resultado de análises reais de requisitos.

É esperado como resultado do trabalho uma análise da viabilidade do uso de um modelo supervisionado de aprendizagem de máquina com o capacidade de lidar com a linguagem natural dos requisitos afim de realizar uma avaliação automática de qualidade. Para considerar a solução como válida, é esperada assim um alto nível de precisão e potencial para exploração de novas características de qualidade.

Este trabalho está dividido da seguinte forma: A Seção 2 apresenta a fundamentação teórica. A Seção 3 aborda trabalhos relativos a classificação da qualidade dos requisitos usando técnicas de aprendizado de máquina. Em seguida, a Seções 4 relata a metodologia e materiais utilizados.

2. Fundamentação Teórica

Nesta seção são detalhados os principais conceitos e técnicas que estão envolvidos na solução do problema apresentado. São eles: Engenharia de Requisitos, Inteligência Artificial, Aprendizado de Máquina e aprendizado supervisionado.

2.1. Engenharia de Requisitos

A Engenharia de Requisitos é a área da Engenharia de Software que fornece o mecanismo apropriado para entender o que o cliente deseja, analisar necessidades, avaliar a viabilidade, negociar uma solução razoável, especificar a solução, validar a especificação e gerenciar os requisitos à medida que são transformados em um sistema funcional [Thayer et al. 1997]. As atividades desse processo incluem: obtenção, análise, especificação, validação, verificação e gerenciamento de requisitos [Pohl 2010].

Os requisitos são definidos por sentenças em linguagem natural e para garantir a qualidade de um requisito individual é necessário que ele siga as seguintes características: necessário, implementação livre, não ambíguo, consistente, completo, singular, viável, rastreável e verificável [ISO/IEC 2018]. A definição de requisitos individuais com qualidade é a etapa inicial para garantia da qualidade de um software.

2.2. Inteligência Artificial

O termo Inteligência Artificial pode ser considerado um conceito relativamente amplo considerando que não há um consenso final sobre seu significado, colecionando um conjunto de definições. Uma das definições mais utilizadas, apesar de não universalmente aceita, é a qual AI é o estudo de como fazer os computadores realizarem tarefas que no momento as pessoas são melhores [Rich 1985].

As diferentes vertentes relacionadas à AI são definidas como estudos das formas de estabelecer comportamentos “inteligentes” nas máquinas. Com o surgimento de novas estratégias de aprendizagem e o aumento do poder de processamento dos computadores, a AI tornou-se uma ferramenta mais acessível ao mercado e ao aprimoramento do desenvolvimento de sistemas de software [Feldt et al. 2018].

2.3. Aprendizado de Máquina

Aprendizado de Máquina (ML, do inglês *Machine Learning*) é uma disciplina da AI composta por um conjunto de técnicas que permitem aos computadores aprender dados e fazer generalizações e previsões a partir de deles, o que facilita a tomada de decisões [Gramajo et al. 2020a]. Embora não seja um conceito novo, a disponibilidade de grandes volumes de dados e maior capacidade de processamento em computadores permitiu experimentar e investigar ainda mais sobre seus usos e aplicações em vários domínios.

Uma das primeiras definições do conceito *Machine Learning* foi o campo de estudo que dá aos computadores a capacidade de aprender algo, para o qual não foram programados explicitamente [Samuel 1959]. Uma definição mais formal é aquela expressa por Mitchell (1997), que afirma que um computador aprende uma tarefa específica T, considerando as experiências do tipo E, com relação a uma medida de desempenho P, se o computador realmente melhorar seu desempenho P, na tarefa T, a partir da experiência E.

2.4. Aprendizado Supervisionado

O aprendizado supervisionado é uma técnica de ML que usa dados rotulados, chamados de dados de treinamento, para construir um modelo preditivo para prever o rótulo de dados não rotulados [Gramajo et al. 2020a]. O conjunto de dados de treinamento inclui dados de valores de entrada e resposta. A partir disso, o algoritmo de aprendizagem supervisionada busca criar um modelo que possa fazer previsões sobre os valores de resposta para um

novo conjunto de dados. Um conjunto é frequentemente usado de dados de teste para validar o modelo. Se são usados maiores conjuntos de dados de treinamento, é possível gerar modelos cuja capacidade preditiva seja maior, obtendo bons resultados em novos conjuntos de dados [Darnstädt et al. 2014].

3. Trabalhos Relacionados

Nesta seção são discutidos estudos que apresentam propostas relacionadas a utilização de aprendizagem de máquina para a avaliação de qualidade de requisitos. Primeiro é abordado um artigo que explora uma abordagem completa de avaliação e sugestão automática de aprimoramento de requisitos. Posteriormente, os dois artigos seguintes exploram a análise de características da qualidade, sendo elas a incerteza e a singularidade, respectivamente. Por fim, os estudos seguintes apresentam um estudo utilizando Redes Bayesianas e, por fim, a identificação de ambiguidades nocivas.

Ter um conjunto de requisitos da mais alta qualidade possível é de enorme importância e os benefícios incluem melhorar a qualidade do projeto, entender melhor as necessidades do cliente, reduzir custos e prever cronogramas e resultados do projeto com maior precisão [Adanza Dopazo et al. 2021]. Assim, o objetivo principal nesse artigo é criar uma metodologia que possa modificar requisitos pobres, extraíndo as principais características de cada requisito, avaliando sua qualidade com alto nível de especialidade e, então, aprimorando o qualidade dos requisitos. Na primeira etapa, foi implementado um algoritmo de aprendizado de máquina para classificar os requisitos com base na qualidade e identificar aqueles que são mais prováveis de serem problemáticos. E na segunda etapa, o algoritmo genético gerou soluções para melhorar a qualidade dos requisitos identificados como inferiores. O algoritmo genético obteve resultados que podem ser comparados com a solução teoricamente ótima, definindo essa ferramenta como promissora para a engenharia de requisitos.

As partes interessadas frequentemente usam linguagem especulativa quando precisam transmitir seus requisitos com algum grau de incerteza [Yang et al. 2012]. Devido à imprecisão intrínseca da linguagem especulativa, os requisitos especulativos correm o risco de ser mal interpretados e a incerteza relacionada negligenciada, e podem se beneficiar de um tratamento cuidadoso no processo de engenharia de requisitos. Neste segundo artigo, é apresentada uma abordagem orientada linguisticamente para a detecção automática de incerteza em requisitos de linguagem natural (NL). Primeiro, são identificadas sentenças especulativas aplicando um algoritmo de aprendizado de máquina chamado Campos Aleatórios Condicionais (CRFs) para identificar pistas de incerteza. O algoritmo explora um conjunto de recursos lexicais e sintáticos extraídos de sentenças de requisitos. Em segundo lugar, a abordagem tenta determinar o escopo da incerteza. É utilizada uma abordagem baseada em regras que se baseia em um conjunto de heurísticas linguísticas feitas à mão para determinar o escopo da incerteza com a ajuda das estruturas de dependência presentes na árvore de análise sintática da frase. Os resultados aparentam promissores para a implementação da avaliação da incerteza de requisitos reais.

Um dos desafios para a avaliação da qualidade de requisitos é lidar com um texto escrito em linguagem natural [Gramajo et al. 2020b]. Neste terceiro artigo Gramajo et al. (2020) propõe outro estudo da qualidade de requisitos desenvolvidos por meio de redes neurais. Utilizando da definição de qualidade definida pela norma ISO/IEC/IEEE

29148:2018, o estudo foca em um dos tópicos de qualidade do requisito, a singularidade. Para isso, é proposto a utilização de redes neurais, do tipo Long Short-Term Memory (LSTM), para prever se os requisitos são singulares ou não. Cada requisito é submetido a um processo de tokenização e rotulagem gramatical, a fim de obter uma sequência representativa que atua como uma entrada para o modelo neural. E então o modelo neural proposto é treinado com um conjunto de dados de 1000 requisitos, sendo 80% para realizar o treinamento da rede neural 10% para teste e 10% para validação. Os resultados apresentados pelo modelo são definidos como promissores e se destaca o interesse em prosseguir a pesquisa com os demais tópicos de qualidade de um requisito.

A área de Engenharia de Requisitos é crucial para o desenvolvimento de um software que não se afaste das necessidades do cliente, mas que muitas vezes é refém da expertise e experiência do profissional responsável [Wiesweg et al. 2020]. Isso é apontado como uma abertura para falhas e, portanto, riscos. Com isso, Wiesweg et al. (2020)], na tentativa de auxiliar esse gerenciamento de risco, desenvolveram solução utilizando Redes Bayesianas. Para isso, foram avaliadas diferentes versões de Redes Bayesianas que modelam as relações entre causas, problemas e efeitos em ER. Os modelos foram treinados com os dados que foram coletados por meio de duas pesquisas com respostas de 228 e 488 profissionais, sobre problemas, causas e efeitos encontrados em projetos reais. Os modelos tinham como objetivo realizar uma análise post-mortem (dado o problema, diagnosticar a causa) e preditiva (dado a causa, diagnosticar possíveis problemas). Ambos modelos apresentaram bons valores de *recall* e precisão, demonstrando uma possível abertura para utilização em gerenciamento de riscos reais.

Em um outro artigo, Yang et al. (2010) propõe identificar automaticamente ambiguidades potencialmente nocivas dos requisitos, que ocorrem quando o texto é interpretado de forma diferente por diferentes leitores. Para isso, foi extraído um conjunto de ambiguidades junto de vários julgamentos humanos sobre suas interpretações. A distribuição de julgamento foi usada para determinar se a ambiguidade é nociva ou inócua. Utilizando técnicas de aprendizado de máquina, foi desenvolvida ferramenta automatizada para prever a preferência antecedente de candidatos a sintagmas nominais, que por sua vez é usada para identificar ambiguidades nocivas. O estudo mostrou resultados que permitem explorar e destacar ambiguidades realistas e potencialmente problemáticas em documentos de requisitos reais.

4. Materiais e Métodos

Referências

- Adanza Dopazo, D., Moreno Pelayo, V., and Génova Fuster, G. (2021). An automatic methodology for the quality enhancement of requirements using genetic algorithms. *Information and Software Technology*, 140:106696.
- Darnstädt, M., Simon, H. U., and Szörényi, B. (2014). Supervised learning and co-training. *Theoretical Computer Science*, 519:68–87. Algorithmic Learning Theory.
- Feldt, R., de Oliveira Neto, F. G., and Torkar, R. (2018). Ways of applying artificial intelligence in software engineering. In *2018 IEEE/ACM 6th International Workshop on Realizing Artificial Intelligence Synergies in Software Engineering (RAISE)*, pages 35–41.

- Gramajo, M., Ballejos, L., and Ale, M. (2020a). Seizing requirements engineering issues through supervised learning techniques. *IEEE Latin America Transactions*, 18:1164–1184.
- Gramajo, M. G., Ballejos, L. C., and Ale, M. (2020b). Hacia la evaluación automática de la calidad de los requerimientos de software usando redes neuronales long short term memory. In *Workshop on Requirements Engineering (WER)*.
- ISO/IEC (2001). *ISO/IEC 9126. Software engineering – Product quality*. ISO/IEC.
- ISO/IEC (2018). *ISO/IEC/IEEE International Standard - Systems and software engineering – Life cycle processes – Requirements engineering*. ISO/IEC.
- Pohl, K. (2010). *Requirements Engineering: Fundamentals, Principles, and Techniques*. Springer Publishing Company, Incorporated, 1st edition.
- Rich, E. (1985). Artificial intelligence and the humanities. *Computers and the Humanities*, 19(2):117–122.
- Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development*, 3(3):210–229.
- Souza, J. H. J., Marques, L. C., Conte, T. U., and Zaina, L. A. M. (2020). Descrevendo requisitos de user experience em critérios de aceitação de user stories. In *Workshop on Requirements Engineering (WER)*.
- Thayer, R. H., Bailin, S. C., and Dorfman, M. (1997). *Software Requirements Engineering, 2nd Edition*. IEEE Computer Society Press, Washington, DC, USA, 2nd edition.
- Wiesweg, F., Vogelsang, A., and Mendez, D. (2020). Data-driven risk management for requirements engineering: An automated approach based on bayesian networks.
- Yang, H., De Roeck, A., Gervasi, V., Willis, A., and Nuseibeh, B. (2012). Speculative requirements: Automatic detection of uncertainty in natural language requirements. In *2012 20th IEEE International Requirements Engineering Conference (RE)*, pages 11–20.